

Exploração de Ferramentas para fins de impacto logístico e financeiro de imprevisibilidade na aviação comercial

Relatório Sumarizado e Não-Técnico

Francisco Silva
Engenharia Informática
Universidade da Madeira
2114821

Sofia Pereira
Engenharia Informática
Universidade da Madeira
2133922

Resumo—Neste documento explora-se a abordagem realizada para descobrir e produzir ferramentas úteis para combater o impacto logístico e financeiro da imprevisibilidade da aviação comercial. Neste projeto visa-se a criação de um sistema de apoio à decisão para antecipar atrasos baseado num histórico de voos de (2019-2023) [6], que mitigam o caro impacto logístico e financeiro da imprevisibilidade da aviação comercial.

Index Terms—Flight Delay Predictions, Machine Learning, Tools for Predicting Delays, Models to mitigate logistic and based decisions for Flight Delays

I. INTRODUÇÃO

A imprevisibilidade dos atrasos na aviação comercial sempre foi um grande problema desta área. Com isto visa-se neste projeto ter criado um modelo com bases o suficiente para fins de previsão com certeza até $\approx 70\%$, o que poderá ajudar a mitigar os custos financeiros e logística através da previsão de atrasos em voos comerciais

II. TRATAMENTO DE DADOS E ENGENHARIA DE FEATURES

A. Desbalanceamento dos Dados

Num ambiente ou área onde cerca de $\approx 82\%$ dos voos comerciais chegam dentro do prazo estipulado, neste caso, "a horas", existe um alto desbalanceamento nos dados disponíveis.

B. Preparação

Para tal é necessário preparar os dados para o modelo as usar. Como tal foram realizadas conversões de dados como nomes, rotas e companhias aéreas em pesos estatísticos que o modelo consiga ler e utilizar.

C. Treino e Realidade

O Treino do modelo para um conjunto de dados equilibrado é essencial, pois força a inteligência artificial a aprender as três realidades operacionais distintas do aeroporto, isto é, permite aprender padrões que ajudam na classificação de dados para 3 tipos diferentes de classes.

- **Classe 0:** Aviões Classificados sem Atraso.

- **Classe 1:** Aviões Classificados com curto Atraso [15-30 Minutos].
- **Classe 2:** Aviões Classificados com Alto Atraso [30+ Minutos].

Pois assim que o modelo vir que na realidade o tráfego aéreo poderá ser muito imprevisível, e majoritariamente populado pela classe 0, não tenha dificuldades ou "aposte" que um voo não estava atrasado, pois a maioria também não estava.

III. A JORNADA PREDITIVA

A. Limitações Estatísticas

Através de vários testes de modelos que seguem padrões lineares para previsão a partir do conjunto de dados, estes demonstraram uma alta dificuldade ao prever corretamente os atrasos no conjunto de dados em momentos de treino. Isto é devido o conjunto de dados e a própria área da aviação ter poucos dados que justifiquem atrasos na maioria dos casos visualizados, sendo estes como: dia da semana, hora de voo, sazonalidade, entre outros.

B. Aplicação de Modelos para Correção e Foco de Erros Sequencialmente

Numa fase de estabilização da previsão através do uso de Ensembles (Uso sequencial de modelos, onde um modelo próximo iria corrigir e focar no erro de previsão do modelo anterior), permitiu que o dados não realistas (ruído) afetassem tanto a previsão dos atrasos nos modelos lineares.

C. Utilização de Inteligência Artificial

Através de Deep Learning, que são modelos que estruturam uma rede Neuronal, como um "cérebro", conseguiram filtrar a maioria dos dados não realistas, permitindo assim terem uma previsão melhorada superando todos os modelos anteriores aqui destacados.

D. Modelo ResNet

Ao contrário dos modelos de Deep Learning falados no tópico anterior, este modelo permitiu ter uma accuracy aproximada das dos modelos anteriores mas uma absoluta precisão de $\approx 74\%$, o que o torna a melhor opção aqui explorada.

Pois de todos os modelos testados, o ResNet foi o único modelo a não ser "preguiçoso" e prever maioria dos casos na fase de teste como classe 0, visto esta no conjunto de dados para teste este ocupa cerca de $\approx 82\%$ do conjunto. Isto porque o ResNet previu uniformemente de igual maneira todas as classes, pois devido a sua arquitetura permite não perder informação ao longo do teste realizado, pela presença de *Skip Connections*, que são um ponto forte para manter a informação em redes neurais longas.

IV. DESCOBERTAS

A. Problema da previsão dos Atrasos em Geral

A partir do estudo dos dados, foi possível que os atrasos não são afetam um perfil específico de voos, por exemplo, um voo atrasado de manhã, possui as mesmas características que um voo de manhã sem atrasos. O que nos leva a conclusão que os atrasos são transversais e circunstanciais.

B. Problema da previsão dos Atrasos Curtos

"A previsão de atrasos curtos continua a ser um problema para qualquer modelo que opere sobre o mesmo tipo de conjunto de dados". Esta afirmação é verdadeira, pois através do estudo foi provado que a classe 1 (Atrasos Curtos) é demasiado volátil e sem qualquer tipo de dado que a justifique, pelo menos neste conjunto de dados, levando á conclusão que é derivada de micro-eventos imprevisíveis como passageiros atrasados, gestão pontual de pista ou bagagens, entre outros..

V. USO DO MODELO DESENVOLVIDO

A. Uso para profissionais

O mesmo modelo poderia ser utilizado através de uma implementação de dashboard que seria operacionalizada por profissionais, que receberiam avisos com uma precisão alta, de possíveis atrasos, permitindo a decisão antecipada, baixando custos logísticos provocado por atrasos.

B. Funcionamento do Modelo

O modelo teria de ser "alimentado" com dados, para tentar prever um possível atraso, esta injeção de dados poderia ser realizada através de uma API ou sistema auxiliar, seguida de um sistema automático que iria executar o modelo e obter uma previsão do voo específico.

C. Manutenção para Consistência

O modelo teria de ser treinado a cada trimestre, para manter um nível de precisão bom o suficiente para a tarefa aqui discutida. A escolha para ser trimestral, vem do facto que o modelo deverá ser treinado para aprender padrões atualizados, pois a aviação está sempre a mudar e assim também ser treinado de acordo a sazonalidade.

D. Desempenho Computacional

Para fins de desempenho computacional e facilidade de uso, o modelo seria aconselhado ser hospedado e utilizado numa nuvem ou contentor específico dele, para fins de previsões rápidas.

VI. VISÃO DO FUTURO

Numa fase mais avançada, poderia ser sugerido a inovação do modelo para o levar a um outro nível de previsão impecável, como a implementação de um sistema que permitisse o modelo utilizar outros dados como: Dados meteorológicos dinâmicos em tempo real, que são ausêntes neste conjunto de dados, para fins de previsão de atrasos ainda mais consistente e dinâmica.

REFERÊNCIAS

- [1] R. Hendrickx, J. Schäfer, M. Zoutendijk, and M. Mitici, "Considering Airport Planners' Preferences and Imbalanced Datasets when Predicting Flight Delays and Cancellations," *2021 IEEE/AIAA 40th Digital Avionics Systems Conference (DASC)*, 2021.
- [2] J. Heaton, "Applications of Deep Neural Networks with Keras," *arXiv preprint arXiv:2009.05673*, 2020.
- [3] P. Zel, "Flight Delay and Cancellation Dataset (2019-2023)," *Kaggle*, 2023.
- [4] S. A. A. AlBassam and D. N. AlShahrani, "Flight delay prediction: Evaluating machine learning algorithms for enhanced accuracy," *PLOS One*, 2025.
- [5] M. H. Asiri *et al.*, "Enhancing Flight Delay Prediction Using Residual Neural Networks (ResNets)," *Metallurgical and Materials Engineering*, 2025.
- [6] U.S. DEPARTMENT OF TRANSPORTATION, Patrick Zelazko, "Flight Delay and Cancellation Dataset (2019-2023)," *Kaggle - Patrick Zelazko, Bureau of Transportation Statistics*, 2024.