

Estudo e Construção de Modelos de Previsão com base em estudos realizados sobre dataset de aviação comercial

Relatório Técnico-Detalhado — Ciência de Dados

Francisco Silva
Engenharia Informática
Universidade da Madeira
2114821

Sofia Pereira
Engenharia Informática
Universidade da Madeira
2133922

Resumo—Este documento apresenta a jornada até ao final de um projeto que se iniciou na investigação e natureza dos dados. Nesta fase inicial, começou-se por analisar padrões evidentes através de EDA e algoritmos para extração de features como também feature selection apoiada por investigação manual e visualizada dos dados através de plots e outros tipos de gráficos associados. Numa fase final, após toda a análise, é realizado um pipeline completo de Machine Learning, onde se abordou a complexidade dos atrasos de voos (on-time, short delay e long delay), como também a implementação de modelos de Ensemble e Deep Learning (MLP) o que permitiu estabelecer um valor máximo de previsão de 54.55% de Accuracy. Paralelo a estes foi utilizado, técnicas de clustering (K-Means) que revelaram que: [...]

Index Terms—Machine Learning, Flight Delay, Deep Learning, K-Means, Imbalanced Data

I. INTRODUÇÃO

O problema principal é a agressiva e completamente aleatória natureza da aviação comercial. Esta pode ser muito difícil de prever, o que dificulta a detetação de atrasos de antecedência. Neste estudo iremos provar que por muito que treinemos um modelo seja ele qual for, este provavelmente não irá ter um resultado positivo todas as vezes, pois como visto em estudos realizados, este tem imensas dificuldades a prever atrasos de curto prazo (0-15 Minutos), pois estes são mais difíceis de prever visto a possível ausência de informação relevante presente no dataset, e como o intervalo é curto, até podem ser motivos não estatisticamente controláveis ou medíveis, como atrasos ou complicações/comportamentos dos passageiros, o que podem ser aleatórios e sem qualquer razão estatisticamente comprovativa.

II. METODOLOGIA E PREPARAÇÃO DE DADOS

A fase inicial, a análise de dados, foi dedicada à formulação do problema, limpeza, pré-processamento e exploração estatística do conjunto de dados *Flight Delay and Cancellation Dataset* (2019-2023). Com o intuito de garantir a robustez dos modelos preditivos e evitar o fenómeno de *data leakage*, todas as variáveis operacionais pós-evento (como o tempo real

de partida ou indicadores diretos de causas de atraso) foram rigorosamente excluídas.

Como parte fundamental do processo de *Data Cleansing*, os valores omissos (*missing values*) e os registos duplicados foram removidos do *dataset*. Adicionalmente, aplicou-se o método estatístico *Z-Score* com um limiar (*threshold*) de 2 para detetar e eliminar *outliers* nas distribuições. Relativamente à variável alvo (*ARR_DELAY*), os valores de atraso negativos - que representam voos que aterraram antes do horário previsto - foram convertidos para 0. Esta decisão justifica-se pelo facto de a otimização logística e a previsão analítica estarem estritamente focadas na mitigação e duração dos atrasos efetivos, não sendo as chegadas sem atrasos um fator principal a ser abordado neste projeto.

Durante a Análise Exploratória de Dados (EDA), realizaram-se investigações sobre três lógicas do ambiente de aviação

- **Rotas e Fluxos Operacionais:** Analisou-se a densidade de tráfego entre os aeroportos de origem e destino (*ORIGIN* e *DEST*) para identificar se determinadas ligações estruturais eram problemas evidente que levassem à propagação de atrasos crónicos.
- **Sazonalidade e Calendário:** Investigou-se o impacto temporal em diferentes granularidades, incluindo a estação do ano, o mês de ocorrência e o dia da semana, procurando padrões de congestão de tráfego ou influências meteorológicas.
- **Horários de Voos:** Avaliou-se a distribuição dos atrasos ao longo das 24 horas do dia, o que permitiu detetar picos severos de atraso médio em intervalos horários específicos e o comportamento de acumulação de atrasos ao longo do dia.

A. Estratégia de Balanceamento e Simulação de Ambiente Real

Para garantir a robustez e a aplicação dos modelos, adotou-se uma abordagem para fins de tratamento de alto desbalanceamento proveniente da aviação comercial no dataset. A

aplicação de técnicas como *resampling* foi utilizada para evitar qualquer tipo de *Data Leakage* entre a fase de aprendizagem e a fase de inferência.

A técnica de *Undersampling* foi aplicada **exclusivamente ao conjunto de treino**. Como resultado, o modelo foi treinado num ambiente equilibrado, com cerca de 415.000 dados distribuídos uniformemente: 33.49% para a Classe 0 (On-time), 33.13% para a Classe 1 (Short Delay) e 33.38% para a Classe 2 (Long Delay). Este balanceamento forçou as redes neuronais e os algoritmos de *Ensemble* a extraírem ativamente os padrões das classes minoritárias, prevenindo o bias de previsão para a classe dominante.

Em contrapartida, o conjunto de teste (composto por aproximadamente 600.000 voos) foi mantido de forma intencional na sua distribuição desbalanceada original: 82.14% na Classe 0, 6.77% na Classe 1 e 11.09% na Classe 2. Esta decisão foi aplicada por fins de realismo, pois num cenário real a avaliação deveria ser estritamente igual à realidade de um aeroporto. Consequentemente, as métricas finais obtidas, como a *Precision* e a *Accuracy*, não são enviesadas por um ambiente laboratorial, refletindo o verdadeiro comportamento do sistema caso fosse implementado hoje em produção.

B. Engenharia de Atributos e Limpeza

Para mitigar os impactos negativos de variáveis categóricas de alta cardinalidade (como as companhias aéreas e as rotas específicas que continham centenas de identificadores únicos), implementou-se a técnica de *Frequency Encoding*. Através deste método, os nomes textuais brutos foram convertidos em métricas estatísticas reais que representam o volume operacional total da transportadora ou o tráfego da rota (*AIRLINE_FREQUENCY* e *ROUTE_FREQUENCY*). Isto permitiu mapear o peso volumétrico e o nível de congestionamento dos grandes *hubs* aeroportuários diretamente nas features, sem injeção de ruído nos algoritmos.

Após a codificação, o dataset foi normalizado para se adequar aos modelos matemáticos usados. Aplicou-se o fluxo de processamento (*pipeline*) utilizando o *StandardScaler* para a padronização das variáveis numéricas contínuas e o *Min-MaxScaler* para o escalamento das features categóricas transformadas, delimitando todos os valores no intervalo $[0, 1]$. Por fim, para lidar com o forte desequilíbrio de classes (*Data Imbalance*) típico da aviação comercial - onde a vasta maioria dos voos cumpre a pontualidade (*On-time*), foi introduzida uma estratégia de *undersampling* aplicada exclusivamente ao conjunto de treino, preservando a distribuição real no conjunto de teste para garantir uma avaliação realista.

C. Redução de Dimensionalidade e Sazonalidade

Com o objetivo de observar a estrutura geométrica subjacente e avaliar a separabilidade do *dataset*, foram aplicadas duas técnicas complementares de redução de dimensionalidade: uma abordagem linear através da Análise de Componentes Principais (*PCA*) e uma abordagem não-linear utilizando o Mapeamento e Projeção Uniforme de Variedades (*UMAP*).

A projeção linear do *PCA* revelou uma grande estrutura rígida composta por sete bandas verticais distintas, determinadas diretamente pela componente principal PC_1 . Esta componente atuou como um identificador temporal do calendário, provando que a variância linear do sistema é dominada pela feature do dia da semana (*FL_DATE_DAY_OF_WEEK*) que apresenta uma clara separação entre o regime de dias úteis e o regime de fim de semana.

Contudo, a visualização mais profunda e a quebra da linearidade foram alcançadas através do *UMAP*. A projeção não-linear isolou o *dataset* em duas grandes "ilhas" ou aglomerados perfeitamente visíveis e detalhados e sem sobreposição central, como observado na Fig. 2. Ao aplicar diferentes mapeamentos de cores, demonstrou-se que esta separação radical é ditada pela distinção binária entre dias úteis e fins de semana (*FL_DATE_IS_WEEKEND*). Através do *UMAP*, conseguimos ver claramente que o comportamento dos voos ao fim de semana (sábado e domingo) é muito diferente dos dias úteis, dividindo os dados em dois grandes grupos bem separados. Além desta divisão, notámos que a Sazonalidade (*SEASON*), na Fig. 1 é o segundo fator com mais impacto. Dentro de cada um desses dois grupos, o algoritmo juntou os voos por estações do ano. Isto faz todo o sentido na prática, visto que o clima e as épocas de férias afetam bastante o tráfego aéreo e os atrasos..




Figura 1: Projeção UMAP evidenciando a separação estrutural por fim de semana.

III. MODELAÇÃO PREDITIVA: K-NN E REGRESSÃO LOGÍSTICA

Numa fase de aprendizagem supervisionada, o principal propósito era o desenvolvimento e a avaliação de modelos capazes de prever o comportamento dos atrasos a partir das características temporais e operacionais e tratadas numa fase inicial. A resolução do problema foi dividida em dois tipos de classificações: Regressão (Focada em estimar o tempo exato




Figura 2: Projeção UMAP evidenciando a separação estrutural por sazonalidade

de atraso em minutos) e Classificação (Focada em estimar o tipo de atraso por classes de intervalo).

Para a classificação, o objetivo consistiu em categorizar cada voo em três estados distintos: Classe 0 (*On-time*, atrasos inferiores a 15 minutos), Classe 1 (*Short Delay*, atrasos entre 15 e 30 minutos) e Classe 2 (*Long Delay*, atrasos superiores a 30 minutos). A estratégia para modelação foi uma realização progressivamente, iniciando-se pela implementação manual e modelos lineares simples (*baselines*), seguindo-se posteriormente por algoritmos baseados em árvores e técnicas de *Ensemble Learning*, e atingindo o ponto mais alto das redes neurais profundas.

A. *k*-Nearest Neighbors (*k*-NN)

Nesta fase procurávamos compreender os algoritmos de classificação não-paramétricos.

Para dar início ao mesmo começou-se pela implementação do zero do algoritmo *K*-Nearest Neighbors (*k*-NN), através do uso da biblioteca *Numpy*.

Este algoritmo baseia-se no cálculo entre a distância euclidiana nas características do voo a testar e o conjunto de treino. Onde será selecionado os *k* vizinhos mais próximos para determinar a classe por maioria de votos.

1) *Regressão*:

a) *Introdução*:

O modelo KNN foi utilizado como base ou ponto de partida para prever os minutos de atraso dos voos. Como este algoritmo funciona com base na proximidade entre dados, era esperado que apresentasse algumas dificuldades num problema tão variável como o da aviação comercial.

b) *Análise de Resultados*:

- **MAE:** Os resultados mostram que o modelo teve um erro médio absoluto (MAE) de 37.83 minutos, o que significa que, em média, as previsões estariam incorretas por cerca de 38 minutos do valor real. Num contexto de voos comerciais, esta margem de erro pode ser significativa,

especialmente em situações de escalas ou ligações entre voos.

- **RMSE:** Através dos valores evidenciados no RMSE de **58.85 minutos**, o que representa um valor muito superior ao MAE, indica que o modelo cometeu erros elevados, isto demonstra que o KNN é bastante sensível a outliers e a dados com muito ruído, algo comum neste tipo de problema.
- **Problema principal:** Ao analisar algumas previsões individuais, observou-se também uma tendência do modelo para sobrestimar atrasos. Em vários casos, o KNN previu atrasos elevados para voos que chegaram praticamente a horas, devido o algoritmo calcular previsões através da média dos vizinhos mais próximos, sendo facilmente influenciado por exemplos extremos presentes nos dados de treino.

c) *Conclusão*:

De forma geral, os resultados demonstram que o KNN não é o modelo mais adequado para prever o número exato de minutos de atraso. Esta análise justifica a ideia para reformular a abordagem ao problema através da classificação por intervalos de atraso e utilizar modelos Ensemble baseados em árvores, que normalmente apresentam maior robustez face a ruído e outliers.

2) *Classificação*:

a) *Introdução*:

Na versão de classificação, o objetivo do modelo KNN deixou de ser prever o número exato de minutos de atraso e passou a ser apenas identificar a categoria correta do voo: sem atraso, atraso curto ou atraso longo.

O objetivo principal era validar se as variáveis possuíam poder preditivo, pois o modelo foi treinado e testado num subconjunto totalmente balanceado. Neste ambiente controlado, um modelo puramente aleatório teria uma accuracy próxima dos 33.3%. O objetivo principal desta experiência foi verificar se as features utilizadas conseguiam fornecer informação suficiente para ultrapassar esse valor antes de avançarmos para o ambiente real desbalanceado, como o conjunto de teste.

b) *Análise de Resultados*:

Os resultados mostram que o modelo atingiu uma accuracy de 46.80%, valor superior ao procurado. Isto indica que existe uma relação entre as variáveis escolhidas e os atrasos reais dos voos, permitindo ao modelo identificar alguns padrões relevantes.

No entanto, ao observar as previsões individuais, verificou-se que o KNN gerou vários falsos positivos, prevendo atrasos em voos que chegaram a horas. Isto acontece porque o algoritmo depende dos vizinhos mais próximos no espaço multidimensional e acaba por ser influenciado por exemplos ruidosos ou casos excecionais presentes nos dados de treino, como evidenciado também na regressão.

c) *Conclusão*:

Apesar de ter atingido uma classificação melhor que os 33% estipulados e criar uma baseline válida para o problema, o KNN revelou limitações na separação das diferentes classes,

principalmente devido à elevada dimensionalidade dos dados e à dificuldade em criar fronteiras de decisão mais flexíveis.

Estes resultados justificam a utilização de modelos mais avançados, como algoritmos de classificação paramétricos e modelos capazes de lidar melhor com relações não-lineares entre as variáveis.

B. Regressão Logística

a) Introdução:

Como modelo linear, foi utilizado a Regressão Logística, pois ao contrário do KNN, que depende da distância entre exemplos/dados, este tenta separar as diferentes classes através de fronteiras lineares.

Aqui, o ambiente é controlado e balanceado como no KNN, com classes distribuídas uniformemente $\approx 33\%$, no dataset de treino, mantendo o dataset de teste desbalanceado como na vida real com a presença de $\approx 82\%$ da classe 0 presente.

b) Análise de Resultados:

- **Comparação com o k-NN:** Os resultados mostram uma ligeira melhoria relativamente ao KNN, atingindo uma accuracy global de 47.93%. Embora o aumento não seja muito elevado, confirma que modelos paramétricos conseguem lidar melhor com datasets com muitas variáveis e dimensões.
- **Análise da Matriz de Confusão:** Através da análise da matriz de confusão, foi evidenciado a alta dificuldade de previsão ou classificação correta para voos da classe 1 (Atrasos curtos), tendo um máximo de **8.855x**, e demonstrando alguma capacidade de classificação para a voos de classe 2 (Atrasos Longos)
- **Problema de Voos de Classe 1:** A classe dos atrasos curtos revelou-se a mais difícil de identificar. Grande parte destes voos foi confundida com voos sem atraso ou com atrasos longos. Isto sugere que os atrasos entre 15 e 30 minutos possuem características não rastreáveis ou evidenciadas pelo dataset, sendo as atuais presentes não muito descritivas sendo normalmente confundidas entre a Classe de Voos 0 e 2.
- **Parâmetro de Regularização:** O Impacto do parâmetro de regularização (C), foi analisado também, visto ser responsável por controlar o ajuste do modelo aos dados. Os resultados mostraram alterações praticamente nulas na accuracy final, o que indica que o modelo já teria atingido o limite ou máximo que consegue aprender através de relações lineares.

c) Conclusão:

De forma geral, a Regressão Logística conseguiu superar ligeiramente o KNN, mas os resultados demonstram que o problema possui relações mais complexas do que aquelas que um modelo linear consegue representar. Assim, torna-se necessário explorar modelos não-lineares, especialmente algoritmos Ensemble baseados em árvores de decisão, capazes de identificar padrões mais complexos e melhorar a separação entre as diferentes classes de atraso.

IV. MODELAÇÃO PREDITIVA: REGRESSÃO NÃO-LINEAR

Como abordado anteriormente, o modelo de regressão linear (*Regressão Logística*), não conseguiu distinguir matematicamente as fronteiras de decisão que separam os voos a horas (*pontuais*) dos voos em atraso, visto estas serem complexas e não-lineares, tornando a regressão logística e outros modelos de regressão linear não ideias para capturar a dinâmica entre os dados.

A. Decision-Tree

Para primeira abordagem de modelos não lineares, utilizamos um algoritmo de decision-tree, pois ao contrário dos modelos lineares de regressão, este algoritmo funciona através de várias decisões lógicas sequenciais, dividindo os dados em diferentes grupos com base nas características dos voos.

1) Análise Preliminar:

a) Expectativa:

A principal ideia, era que esta abordagem conseguisse lidar melhor com casos mais difíceis, especialmente a Classe 1 (Short Delay), que evidenciou inúmeros problemas para modelos anteriores.

2) *Abordagem e Resultados:* Durante os testes, foram avaliadas diferentes profundidades máximas da árvore (*max_depth*) para encontrar um equilíbrio entre capacidade de aprendizagem e generalização. O melhor resultado foi obtido com *max_depth* = 10, atingindo uma accuracy de 41.26%.

3) *Análise ao Resultado obtido:* Apesar de ser uma abordagem mais flexível, o desempenho ficou abaixo da Regressão Logística e do KNN. Além disso, verificou-se que aumentar a profundidade da árvore piorava continuamente os resultados no conjunto de teste, visto que à medida que a árvore fazia mais divisões e criava regras mais específicas, começou a memorizar os dados de treino em vez de aprender padrões gerais, fracassando assim em fases de avaliação.

Este comportamento demonstra um caso claro de overfitting. O modelo tornou-se demasiado adaptado aos exemplos de treino e perdeu capacidade de generalizar para novos dados.

4) *Conclusão:* De forma geral, os resultados mostram que uma única árvore de decisão é demasiado instável para um problema com tanto ruído e variabilidade como os atrasos na aviação. No entanto, a utilização de regras não-lineares revelou potencial, justificando a utilização de modelos Ensemble, como o Random Forest, que combinam múltiplas árvores para reduzir o impacto do overfitting e melhorar a estabilidade das previsões.

Em suma, a árvore de decisão singular, provou ser demasiado instável e sensível a ruído presente no dataset. Embora a sua base lógica (não-linear) seja o necessário, a sua execução isolada é sensível e frágil. O que justifica o uso de modelos Ensemble, nomeadamente Bagging, que irá resolver, por norma, a fraqueza ao estabilizar o ruído.

V. MODELAÇÃO PREDITIVA: EMSEMBLE MODELS

Para superar estas limitações anteriormente referidas, avançamos para *Ensemble Learning*, que combina as previsões

de múltiplos modelos individuais para construir um classificador final mais robusto. Foram exploradas duas abordagens principais **Bagging Classifier** e **Boosting AdaBoost**.

A. Bagging Classifier

1) Introdução:

Depois de verificarmos que uma única Decision Tree sofria bastante de overfitting, foi utilizada uma abordagem Ensemble através do algoritmo Bagging Classifier. O objetivo principal foi reduzir a instabilidade observada anteriormente, combinando várias árvores de decisão em vez de depender apenas de uma.

2) Abordagem:

Foram criadas 15 árvores independentes utilizando a técnica de Bootstrap Sampling, onde cada árvore é treinada com subconjuntos diferentes do dataset. Na fase de previsão, todas as árvores votam na classe final do voto, permitindo reduzir o impacto de erros individuais e melhorar a estabilidade do modelo.

3) Resultados:

Os resultados mostraram uma melhoria significativa relativamente aos modelos anteriores. O Bagging atingiu uma accuracy global de 52.51%, tornando-se o melhor modelo testado até este ponto e ultrapassando claramente os modelos lineares, como a Regressão Logística.

4) Robustez e Variação:

Durante a cross validation, o modelo apresentou resultados muito consistentes entre diferentes divisões dos dados, com variações muito pequenas entre os grupos. Isto demonstra que o Bagging conseguiu reduzir bastante a variância e aumentar a robustez das previsões.

5) Análise Matriz de Confusão:

A análise da matriz de confusão mostra que o modelo teve um bom desempenho na identificação de voos sem atraso, acertando corretamente um grande número destes casos, como também na identificação de atrasos longos com resultados relativamente bons.

6) Principal Problema:

A Classe 1 (Short Delay) continuou a ser a categoria mais difícil. Tal como nos modelos anteriores, muitos destes voos foram confundidos com voos sem atraso ou com atrasos longos, mostrando que esta continua a ser uma área difícil de classificar.

7) Conclusão:

O Bagging provou que a utilização de várias árvores melhora e estabiliza o modelo, como também o seu resultado final de accuracy. Apesar desta melhoria, a classe 1 (Short Delay) continua a ser um problema comum entre todos os modelos até este ponto atual. O que justifica o uso e exploração de algoritmos de Boosting, capazes de se focar nos erros cometidos em iterações anteriores, para resolver a aprendizagem das classes mais ambíguas.

B. Boosting Classifier - AdaBoost

1) Introdução:

Apesar de uma melhoria com um accuracy mais alto de 52.51%, o Bagging trabalha em paralelo e não corrige os erros cometidos pelas árvores anteriores.

2) Abordagem:

Com isto, a abordagem escolhida envolve a utilização do AdaBoost, com *max_depth* de 5, como aprendizes fracos. Este irá construir árvores sequencialmente (série). Cada árvore aprende os erros da anterior, dando um peso maior para voos que foram mal classificados na iteração anterior. Esta foi a mais apropriada, na nossa visão, pois assim o modelo iria criar regras mais forçadas e específicas para classe 1 (Short Delay).

3) Resultados:

O AdaBoost apesar de tentar resolver o problema do Bagging, conseguiu apenas uma avaliação de 47.95%, não superando o accuracy do Bagging.

4) Análise de Resultados:

Enquanto que o aumento do nº de dados alimentados ao modelo, no Bagging este pareceu estabilizar mais que o próprio boosting, que ficou com imensa dificuldade ao tentar distinguir classes com fronteiras tão próximas, devido ser altamente adaptativo, acabando por aprender erros aleatórios (ruído) em vez de padrões globais.

5) Análise Matriz de Confusão:

A análise da matriz de confusão revelou que o modelo consegue com alta fiabilidade classificar voos comerciais sem atrasos, mas quando se trata das Classes 1 e 2, o problema é evidente, os modelos têm uma alta dificuldade a prever estas duas classes devido a natureza aleatória da aviação e ambiguidade entre as duas classes.

6) Conclusão:

O Bagging é o modelo vencedor, a sua capacidade de isolar o ruído através de árvores independentes provou ser superior à estratégia de "correção de erros" do AdaBoost para este cenário específico.

VI. MODELAÇÃO PREDITIVA: DEEP LEARNING (MLP)

Após uma exploração em Ensemble Learning, procuramos explorar modelo em Deep Learning, neste caso **MLP (Multi-Layer Perceptron)**, uma rede neuronal artificial feedforward capaz de aprender relações não-lineares complexas projetando os dados em dimensões superiores.

A. Abordagem Científica - DL 1 Camada 100 Neurons [1]

Para abordagem científica, foi selecionado como artigo científico o [1], para fins de estrutura do modelo e abordagem como parâmetros de configuração.

O estudo demonstra que, para conjuntos de dados de aviação, o Accuracy não é a métrica mais relevante. Na visão do estudo, defende-se que para fins de previsão de atrasos terá de existir uma elevada certeza de previsão para tomadas de decisões sólidas, passando assim a ser monitorizado o Precision e F1-Score, não ignorando com totalidade a Accuracy para fins de comparação com outros modelos.

1) *Arquitetura*: Para esta parte utilizou-se a estrutura otimizada provada na Tabela III do artigo referido [1].

Tabela I: Hiperparâmetros e Topologia da Rede Neuronal (Abordagem Hendrickx et al.)

Hiperparâmetro / Componente	Configuração Adotada
Arquitetura Base	Multi-Layer Perceptron (MLP)
Config. das Camadas Ocultas	1 Camada Oculta (100 Neurônios)
Função de Ativação	ReLU (<i>Rectified Linear Unit</i>)
Algoritmo de Otimização (<i>Solver</i>)	Adam
Limite Máximo de Épocas (<i>max_iter</i>)	300
Fração de Validação Interna	10%
Critério de Paragem Antecipada	<i>Early Stopping</i> Desativado (<i>False</i>)
Estratégia de Validação Externa	Validação Cruzada K-Fold ($K = 3$)

2) *Early Stopping*: O algoritmo foi pensado e desenvolvido com *Early Stopping* em si, este permitia o modelo não ficar preso em tempos de execução extensos ao "pensar" que estaria já com a melhor previsão. Para alguns casos revelou-se boa, por outros lados não. Sendo assim desativada, para qualquer tipo de testes daqui em diante.

3) *Análise de Resultados*:

a) *Impacto da Arquitetura*:

Após ser adotado uma arquitetura validada por [1], com uma única camada de 100 neurónios, esta revelou-se não ter o melhor resultado, com uma **precision** de (37.62%) e **F1-Score** (33.67%), que acabam por confirmar uma extrema dificuldade na previsão de resultados com certeza absoluta, num dataset com muito ruído, o que justifica a razão pelo qual os aeroportos lidam diariamente com imprevistos operacionais.

A Accuracy fixou-se nos 48.29%, inferior ao modelo de Bagging, o que prova que as distribuições e características dos dados exigem uma estrutura de compressão mais agressiva e não apenas uma rede plana de (100 neurónios) idealizada para os dados de estudo em [1]

b) *Matriz de Confusão*:

O modelo conseguir prever sem dificuldade as classes 0 e 2, com 246K e 34.163K classificações corretas, respetivamente. Já a classe 1, demonstra ser um problema até para esta configuração de deep learning, pois uma rede com apenas uma camada ainda causa alguma hesitação na previsão desta classe. Mas este problema não é um problema direto do poder computacional do modelo mas sim também a aleatoriedade em atrasos de curto tempo.

4) *Conclusão*:

A transição para modelos de deep learning guiada por parâmetros estabelecidos em [1], permitiu uma avaliação mais focada num exemplo real de aplicação. Neste caso do estudo para fins de Planeamento de Aeroportos.

B. Abordagem Científica - DL 2 Camadas em Funil (64/32) [2]

Após exploração do modelo focado no uso de 1 camada com 100 Neurónios, procuramos expandir a nossa abordagem, com base em outras fontes, como [2]. Que explica e aprofunda a otimização de redes neuronais para dados multivariados.

1) *Arquitetura*: Ao contrário da versão 1, nesta versão procuramos usar uma tipologia defendida pelo autor [2]. Nesta o autor defende uma arquitetura de compressão progressiva, isto é, a utilização de 2 camadas de 64 e 32 neurónios cada respetivamente, podendo ser definida como arquitetura ou **topologia em Funil**.

Tabela II: Hiperparâmetros e Topologia da Rede Neuronal (Abordagem Heaton - Funil)

Hiperparâmetro / Componente	Configuração Adotada
Arquitetura Base	Multi-Layer Perceptron (MLP)
Config. Camadas Ocultas	2 Camadas (64 e 32)
Função de Ativação	ReLU (<i>Rectified Linear Unit</i>)
Algoritmo de Otimização (<i>Solver</i>)	Adam
Limite Máximo de Épocas (<i>max_iter</i>)	300
Critério de Paragem Antecipada	<i>Early Stopping</i> Desativado (<i>False</i>)
Épocas de Treino Efetivas	67 Épocas
Estratégia de Validação Externa	Validação Cruzada K-Fold ($K = 3$)

2) *Early Stopping*: Como afirmado anteriormente, o *Early Stopping* foi desativado para este algoritmo.

3) *Análise de Resultados*:

a) *Recuperação de Poder Preditivo*:

Com a aplicação de uma topologia em funil, proposta pelo autor [2], o modelo conseguiu uma melhor accuracy em relação à outra versão de Deep Learning como também em relação aos outros modelos anteriormente discutidos, com um valor de **54.55%**.

b) *Eficácia de Compressão de Características*:

Esta versão do modelo conseguiu atingir um novo nível de *accuracy* devido à sua arquitetura, pois consegue filtrar melhor o ruído que os outros modelos. Pois a dupla camada permite reforçar a uma "noção" dos motivos pelos atrasos.

c) *Classe 1*:

Mesmo assim, a classe 1 continua a ser um grande problema para até este modelo. O que demonstra que a área de previsão para a classe 1 é muito irregular e aleatória, devido à ausência de padrões distintivos entre outras classes. O que reforça que os atrasos de Classe 1 [**15-30 Minutos**] são de origens não captáveis dentro do dataset que temos disponível.

4) *Conclusão*: Este modelo permite finalmente identificar que o problema não é os modelos, a classe 1 realmente tem uma irregularidade e é muito aleatória, o que nos leva à conclusão que existe dados essenciais e não capturados no dataset que expliquem um padrão característica desta classe. Em suma, o modelo conseguiu a melhor accuracy e previsão de todos os modelos até ao momento como visto na Fig. 3, sendo a classe 1 a mais difícil de prever corretamente diante a totalidade do dataset.

C. Abordagem Científica - DL ResNet [5]

Após explorarmos as arquiteturas planas e de compressão em funil, procurámos testar uma abordagem que fosse mais adaptada à presente no dataset. Pois os modelos anteriores




Figura 3: Projeção Gráfica da diferença de Accuracy entre Modelos Explorados.

seriam mais eficazes em casos com Dados Meteorológicas associados a cada voo no dataset.

Para tal, fundamentámo-nos na literatura recente de redes profundas aplicadas á aviação comercial, especificamente no estudo [5]

1) *Arquitetura*: Enquanto que nos modelos anteriores os dados passavam de camada a camada, quanto mais profunda fosse a rede menor seria o gradient.. com isto a arquitetura de Resnet resolve este problema através de *Skip Connections*, isto é, ligações que permitem que os dados de entrada "saltem" determinadas camadas e serem aglomeradas posteriormente, o que evita o *Vanishing Gradient*.

Tabela III: Hiperparâmetros e Topologia da Rede Neuronal (Abordagem Asiri et al. - ResNet)

Componente	Configuração Adotada
Arquitetura Base	Rede Neuronal Residual (ResNet Tabular)
Framework e API	TensorFlow / Keras (<i>Functional API</i>)
Config. de Blocos Residuais	2 Blocos Residuais (64 neurónios cada)
Mecanismo de Conexão	<i>Skip Connections</i> com Add
Camada de Compressão Final	1 Camada Densa (32 neurónios)
Função de Ativação	ReLU (<i>Rectified Linear Unit</i>)
Algoritmo de Otimização	Adam
Técnicas de Regularização	<i>Batch Normalization</i> e <i>Dropout</i> (0.2)
Limite Máximo de Épocas	60 Épocas
Crítério de Paragem Antecipada	<i>Early Stopping</i> Ativado (<i>patience</i> =10)
Estratégia de Validação	20% <i>Validation Split</i>

2) *Early Stopping*: O Early Stopping foi ativado para não permitir uma execução demasiado extensa do modelo. Evitando assim muito tempo de cálculo computacional, e mantendo a lógica do modelo de forma a permitir uma análise crítica entre outros modelos.

3) *Análise de Resultados*:

a) *Precisão e Confiança*:

Em relação a outros modelos, esta arquitetura baseada em ResNet permitiu atingir um nível de precisão e confiança

bastante bom. A precision com um valor de 74.60%, que é uma grande conquista, pois indica que o modelo é bastante preciso para o tipo de dataset desbalanceado presente.

Já o F1-Score também subiu ligeiramente, com uns 58%.

b) *Porquê o ResNet é melhor?*:

A descida ligeira na accuracy face aos outros modelos justifica-se pela presença de $\approx 82\%$ no dataset de teste. Enquanto os outros modelos foram mais conservadores ao tentar classificar a maioria como Classe 0 para inflacionar a accuracy global, a ResNet tentou prever de igual forma todas as classes de atrasos uniformemente, permitindo assim uma accuracy bem mais alta que os outros modelos.

4) *Conclusão*: Todos os modelos foram treinados com um dataset equilibrado, onde a maioria cedeu o bias para a classe 0 assim que foram avaliados no dataset de teste real e desbalanceado. A ResNet, não foi afetada com o dataset de teste devido á presença de *Skip Connections*, que permitiram evitar a perda de informação (*Vanishing Gradient*) não ignorando padrões que justificassem os atrasos. Desta forma, num cenário de uso real em um aeroporto, este modelo teria mais probabilidade de ser utilizado mesmo tendo uma accuracy menor, visto ter uma precisão muito maior, assim evitando o excesso de falsos negativos.

VII. APRENDIZAGEM NÃO-SUPERVISIONADA: CLUSTERING

Até este ponto do projeto, houve um foco na previsão do tempo de atrasos dos voos, algo que foi conseguido através de modelos de aprendizagem supervisionada. No entanto, também é relevante perceber as causas dos atrasos e como as características dos aeroportos impactam a pontualidade dos voos.

Um modelo de clustering foi utilizado neste projeto com o objetivo de encontrar padrões ocultos nos aeroportos. Os aeroportos foram agrupados em clusters e os mesmos foram analisados de modo a identificar padrões dentro deles.

A. K-Means e a Estrutura dos Dados

a) *Introdução*:

O *K-Means* é um modelo de aprendizagem não-supervisionado que agrupa dados em K clusters, que são ajustados a cada iteração de modo a minimizar a variância dentro do cluster.

O algortimo foi treinado com dados de perfis de aeroportos pré-processados e normalizados, de modo a alcançar clusters que melhor representem os aeroportos. Esta abordagem permitiu verificar se os atrasos previstos pelos modelos anteriores têm alguma correlação com os aeroportos de origem dos voos.

b) *Determinação do Número Ideal de Clusters (K)*: Para definir o valor ideal de K (clusters) a criar através do *K-Means* foi feita uma análise dos valores de inércia, com K a variar de 2 a 12, e o *Silhouette Score*. Após esta análise, ficou claro que $K = 3$ é o valor ideal de clusters de aeroportos.

- **Crítério do Silhouette Score**: O valor de K que gerou o melhor *Silhouette Score* foi $K = 3$: **0.2965**. A partir de $K = 4$, esta métrica tem uma queda acentuada.




Figura 4: Elbow Method




Figura 5: Análise de Silhueta

- **Método do Cotovelo (Elbow Method):** A estabilização do valor de inércia começa a se estabilizar a partir de $K = 3$ (1491.72). O ganho computacional e a redução da variância dentro dos clusters ao passar para valores de K superiores tornam-se pouco relevantes, não justificando o aumento da complexidade do modelo.

c) *Análise de Resultados:*

Os resultados obtidos através do K -Means permitiram gerar 3 perfis de aeroportos. Uma característica identificada nos 3 clusters é o bloco horário com maior número de voos: bloco das 6 da manhã. As restantes características permitem a distinção dos clusters, ou seja, descrevem perfis distintos. Estas características estão descritas na tabela IV.

A caracterização de cada grupo revela os seguintes comportamentos dos aeroportos:

- **Cluster 0 (Aeroportos Instáveis e Voos Curtos):** Este grupo, com um volume total de 17.510 voos, apresenta a menor média de tráfego por aeroporto (≈ 389 voos) e possui maioritariamente rotas curtas (média de 463.09 milhas). Apesar da baixa densidade, provou ser o grupo **operacionalmente mais instável do país**, dado que possui o maior atraso médio (**25.20 minutos**). O principal fator a influenciar os atrasos deste grupo são os erros as-

Tabela IV: Métricas Médias e Perfis de Negócio Gerados pelo K -Means

Métrica	Cluster 0	Cluster 1	Cluster 2
ARR_DELAY (min)	25.20	13.84	12.66
DELAY_DUE_WEATHER (min)	2.73	0.58	1.21
DELAY_DUE_NAS (min)	2.44	2.91	1.84
DELAY_DUE_CARRIER (min)	11.56	3.98	4.47
DISTANCE (milhas)	463.09	897.60	398.63
FLIGHT_VOLUME (média/hub)	389.11	27472.51	2081.49
Companhia Dominante (Moda)	SkyWest	Southwest	SkyWest
Total de Voos na Amostra	17.510	2.472.526	509.964

sociados à companhia aérea ($DELAY_DUE_CARRIER$ de 11.56 minutos) e os fenómenos meteorológicos (2.73 min de atraso médio por fenómenos meteorológicos adversos). O cluster é dominado pela **SkyWest Airlines Inc.**

- **Cluster 1 (Aeroportos de Grande Tráfego e Longa Distância):** Este é o **núcleo central do tráfego aéreo**, contendo a maioria dos registos da amostra (mais de 2.47 milhões de voos). O cluster é composto por aeroportos com voos predominantemente de longas distâncias (maior média de distância, com **897.60 milhas**) e um volume elevado de tráfego (27.472 voos médios). Embora os aeroportos deste grupo operem um número elevado de voos, apresenta uma estabilidade maior quando comparado com o Cluster 0, tendo apenas 13.84 minutos de atraso médio. O valor de atraso médio mais elevado é o causado por controlo de tráfego nacional ($DELAY_DUE_NAS$ com 2.91 minutos). Os aeroportos deste cluster são operados maioritariamente pela **Southwest Airlines Co.**. O cluster pode ser caracterizado pela alta eficiência de gestão operacional em aeroportos com grande tráfego.
- **Cluster 2 (Aeroportos Pequenos e Voos Curtos):** Este grupo é representado por aeroportos que incluem 509.964 voos. Os aeroportos possuem rotas predominantemente curtas (398.63 milhas médias) e tráfego relativamente baixo (≈ 2.081 voos por hub). O perfil destes aeroportos é o mais pontual, apresentando o menor atraso médio registado (**12.66 minutos**). O espaço aéreo dos voos apresenta um congestionamento baixo e a taxa de atraso por gestão de espaço aéreo é também a mais baixa (NAS de apenas 1.84 min). A operadora dominante volta a ser a **SkyWest Airlines Inc.**. Nestes cluster podemos observar que havendo um baixo tráfego e congestionamento, e voos curtos (regionais) é possível manter fluxos de tráfego previsíveis e controlados (baixos atrasos).

d) *Conclusão:*

O uso do algoritmo K -Means foi crucial para melhorar a compreensão do problema, revelando a existência de 3 perfis principais de aeroportos distintos, com impactos relevantes nos valores médios de atraso.




Figura 6: Matriz 2 a 2 K-Means (atrasos)




Figura 7: Matriz 2 a 2 K-Means (estrutura)

VIII. AVALIAÇÃO E COMPARAÇÃO FINAL

A. Modelos Lineares

A fase de modelação iniciou-se com a exploração de modelos de **regressão linear**, onde se evidenciou que estes modelos ficariam estagnados num valor de accuracy próximo dos 47.9%, o que revelou que este tipo de abordagem seria insuficiente para a complexidade do dataset.

B. Model Ensembling

Com model **Ensembling**, maioritariamente falando da abordagem utilizada no Bagging, conseguiu-se através

da combinação de múltiplas árvores de decisão, uma estabilização da *accuracy* casa dos 52.51%.

C. Deep Learning

Foi através do Deep Learning mais propriamente através da abordagem por MLP em Funil, onde se atingiu o maior accuracy na totalidade do projeto, com o valor de 54.55%.

O problema principal é que esta accuracy como também no outro MLP abordado de 1 camada e 100 Neurons, é que estes modelos focaram-se maioritariamente na classe 0 (Voos sem atrasos), visto ser a classe majoritária no dataset, permitindo assim um maior accuracy e menor precision com 38.08%.

D. ResNet

O Uso da arquitetura ResNet permitiu atingir uma accuracy próxima dos Modelos MLP, mas com uma precisão elevada, superando assim os outros modelos, isto porque ao contrário do modelo MLP, o ResNet procurou aprender corretamente todas as classes através de Skip Connections o que permitiu não se focar na classe maioritária (Classe 0), tendo assim uma precisão final de 74.60% e um F1-Score de 58.44%.

E. Problema Principal Identificado

Apesar desta jornada ter bons resultados, existe um problema que é muito evidenciado.. a Classe 1 (Atrasos Curtos) o que traduz não ser um problema dos modelos em si, mas a alta dificuldade e falta de informação no dataset. Visto se tratarem de atrasos curtos, não existem padrões identificáveis para prever corretamente esta classe, pois as causas estariam não presentes no dataset.

Tabela V: Comparação de Performance dos Modelos de Classificação

Modelo	Accuracy	Precision (M)	F1-Score
Log. Regression	47.93%	-	-
Bagging Classifier	52.51%	-	-
MLP (100 Neurónios)	48.29%	37.62%	33.67%
MLP Funil (64, 32)	54.55%	38.08%	36.16%
ResNet Tabular (Asiri et al.)	51.02%	74.60%	58.44%




Figura 8: Projeção Gráfica de Performance entre Deep Learning Models

F. Melhor Modelo para Produção?

Pela análise feita, o ResNet seria o melhor modelo para fins de produção, visto a sua alta precisão. Os MLP's seriam uma escolha incorreta, pelo simples motivo de ignorarem demasiados atrasos, criando assim *false positives*, com muita frequência.

IX. RESUMO DE DESCOBERTAS REALIZADAS

Tabela VI: Resumo das Principais Descobertas e Conclusões do Projeto

Fase / Abordagem	Principal Descoberta Preditiva e de Negócio
Modelos Lineares (Regressão Logística)	O dataset é demasiado complexo para modelos lineares, estagnando nos $\sim 47\%$ de Accuracy.
Modelos de Ensemble (Bagging Classifier)	A agregação de múltiplas árvores de decisão estabilizou o ruído, elevando a Accuracy para 52.51% .
MLP em Funil (Compressão 64 $\rightarrow$ 32)	Uso de camada dupla permitiu a eliminação forçada do ruído, trazendo um record de Accuracy de 54.55% . Apesar disso os modelos MLP, focaram-se muito na classe maioritária do dataset (Classe 0), inflacionando a Accuracy obtida.
ResNet Tabular (Ligações Residuais)	ResNet é o melhor modelo dos testados. A sua arquitetura permite não esquecer variáveis originais, sacrificando ligeiramente a Accuracy global para atingir uma altíssima precisão de 74.60% , sendo assim o modelo ideal para aeroportos cujo necessidade seja a precisão de alertas deste tipo.
Clustering (K-Means) (Não-Supervisionado)	Identificou três perfis estruturais de aeroportos ($K = 3$, <i>Silhouette</i> ≈ 0.30) com base no tráfego e causas de atraso. Provou que a rede aérea é assimétrica e tem impactos relevantes nos valores médios de atrasos dos voos.
Problema em Comum (A Classe 1)	Em comum entre todos os modelos, temos a previsão incorreta da classe 1, todos os modelos tiveram dificuldades nesta tarefa devido a natureza aleatória dos atrasos de curto tempo (Atrasos por passageiros, entre outros), visto o dataset não permitir adquirir padrões que sejam identificadores deste tipo de atrasos.

X. PLANO DE IMPLEMENTAÇÃO EM PRODUÇÃO

A. Ingestão de Dados em Tempo Real

A nosso ver, num nível de produção o sistema dispensaria o uso de ficheiros estáticos (CSV), onde a arquitetura seria modificada para sistemas de gestão de tráfego aéreo (ex: FAA) através de uma API.

Assim que um plano de voo fosse registado, seria enviado para o sistema os dados necessários para o modelo trabalhar corretamente.

B. Pipeline de Pré Processamento Automático

Após receção dos dados, estes seriam de imediato processados pela classe **data_loader**, para fins de transformação idêntica aos usados nos dados de treino.

Em seguida, seriam retiradas por ordem variáveis ou features invisíveis como: Sazonalidade, Calendário, Frequency Encoding e conversão de variáveis categóricas no seu respetivo peso estatístico.

C. Alojamento do Modelo

Para fins de alojamento e alto processamento computacional, o modelo previamente treinado e serializado seria enviado e carregado via **.pkl**, numa cloud ou Docker, permitindo assim o cálculo do atraso associado em frações curtas de tempo.

D. Uso e Aplicação do Modelo

O modelo através de um dashboard controlado e observado por profissionais, permitiria estes através de uma % de classificação e precisão permitir a administração de decisões e aplicações de segurança para voos comerciais assinalados com atrasos específicos.

E. Ciclo de Vida e Treinos Periódicos

Para evitar degradação do modelo ao longo do tempo, o sistema exigiria uma manutenção. Isto pois a aviação está em constante alteração, sendo assim classificado como um ambiente dinâmico, sub imensas alterações sejam estas rotas ou aeroportos novos.

Para tal seria implementado um pipeline de treino do modelo automatizado, por exemplo a cada trimestre de forma a garantir que os pesos e frequências, como também os padrões identificados pelo modelo seguem a "realidade" atual do tráfego aéreo.

XI. CONCLUSÕES E TRABALHO FUTURO

A. Síntese do Problema

Esta fase do projeto tinha como objetivo, com base no dataset disponibilizado, a construção de modelos que permitissem prever atrasos de voos (aprendizagem supervisionada) e traçar perfis de aeroportos, de modo a inferir como estes impactam os tempos de atrasos. Os modelos desenvolvidos são ferramentas que permitem, num futuro, mitigar impactos logísticos e financeiros da imprevisibilidade da aviação comercial.

B. Abordagem aos dados

De forma a mitigar este foram realizadas extração manual de features e características após uma análise aprofundada dos dados e das suas correlações. Posteriormente, foram serializados, normalizados e retirados dados que pudessem causar data leakage para o conjunto de dados, melhorando o potencial de previsão dos modelos sem que os mesmos sejam viciados por data leakage.

C. Previsão e Estrutura

Através da análise na fase de Clustering foi possível identificar que a afirmação "quanto maior for o tráfego maior seria o problema logístico", não é correta, mas sim que num grande hub (Cluster 1), apesar da alta operação de milhões de voos, o ambiente é bastante eficiente, onde os atrasos são derivados da gestão do espaço aéreo. Por outro lado, foi também identificado que alguns aeroportos com menos tráfego podem ser os mais instáveis, sofrendo atrasos severos, possivelmente devido causas internas das próprias transportadoras.

D. Problema da estrutura nos modelos

Através da análise de clustering, validou-se o comportamento realizado pelos modelos preditivos. Estes apresentaram dificuldades na previsão de atrasos pois tentam aplicar uma lógica universal sobre problemas que mudam de lógica dependendo do perfil de aeroporto de origem. Isto torna justificável a transição para arquiteturas de Deep Learning, para que o sistema consiga prever um atraso com precisão, através do uso de redes neurais, que permitem manter relações não-lineares.

E. ResNet e outros Modelos DeepLearn

Dado que 82% dos voos pertenciam à classe 0 (sem atraso), modelos como o KNN e *Decision Tree (Lazy Learners)* sofrem de um enviesamento (*bias*), classificando praticamente todos os voos como pertencentes à classe 0. O *ResNet* é um modelo poderoso em *datasets* como este, devido à sua arquitetura: através de *Skip Connections*, mantém relações não-lineares entre os dados, corrigindo o problema do *bias* introduzido por esta classe.

F. Classe Problemática

Os algoritmos de classificação desenvolvidos tiveram o seu desempenho afetado pela classe 1 (atrasos curtos). Esta classe revelou-se problemática uma vez que atrasos inferiores a 15 minutos, por vezes, devem-se a situações de pouca relevância que não podem ser previstas pelos modelos.

G. Dashboard

Foi produzido um pequeno dashboard onde é possível verificar todos os valores obtidos por parte dos modelos, como também a previsão de voos específicos do conjunto de teste, no momento, assim provando a aplicabilidade do modelo numa situação adequada ao mesmo.

H. Futuro

Numa fase futura, os modelos desenvolvidos neste projeto poderiam ser enriquecidos integrando dados meteorológicos em tempo real, aumentando o seu poder preditivo e tornando-os mais consistentes.

REFERÊNCIAS

- [1] R. Hendrickx, J. Schäfer, M. Zoutendijk, and M. Mitici, "Considering Airport Planners' Preferences and Imbalanced Datasets when Predicting Flight Delays and Cancellations," *2021 IEEE/AIAA 40th Digital Avionics Systems Conference (DASC)*, 2021.
- [2] J. Heaton, "Applications of Deep Neural Networks with Keras," *arXiv preprint arXiv:2009.05673*, 2020.
- [3] P. Zel, "Flight Delay and Cancellation Dataset (2019-2023)," *Kaggle*, 2023.
- [4] S. A. A. AlBassam and D. N. AlShahrani, "Flight delay prediction: Evaluating machine learning algorithms for enhanced accuracy," *PLOS One*, 2025.
- [5] M. H. Asiri *et al.*, "Enhancing Flight Delay Prediction Using Residual Neural Networks (ResNets)," *Metallurgical and Materials Engineering*, 2025.
- [6] U.S. DEPARTMENT OF TRANSPORTATION, Patrick Zelazko, "Flight Delay and Cancellation Dataset (2019-2023)," *Kaggle - Patrick Zelazko, Bureau of Transportation Statistics*, 2024.